



@ki_tech_tipps

Gratis-Ratgeber · KI & Technik

RATGEBER ZUM INSTAGRAM-POST

KI ohne Cloud: Sprachmodelle lokal auf dem eigenen Rechner nutzen

Was ein lokales Sprachmodell ist, welche Hardware du brauchst, wie du startest und wo die Grenzen gegenüber großen Cloud-Diensten liegen.

7. Oktober 2026 · Lesezeit ca. 5 Min. · 10 Seiten

DAS LERNST DU IN DIESEM RATGEBER

- 1 Prüfe den Arbeitsspeicher deines Rechners, bevor du ein Modell auswählst.
- 2 Starte mit einem kleinen Modell und einem Programm mit grafischer Oberfläche.
- 3 Lies die Lizenz des Modells, bevor du es beruflich nutzt.
- 4 Prüfe Fakten aus lokalen Modellen genauso gegen wie bei Cloud-Diensten.

Inhalte KI-generiert, ohne Gewähr. Keine Rechts- oder IT-Sicherheitsberatung.

Inhalt KI-generiert · Alle Ratgeber gratis unter www.tipps-ratgeber.de

Worum es geht

Die meisten KI-Chats laufen auf Servern großer Anbieter. Jede Eingabe wird dorthin geschickt und dort verarbeitet. Inzwischen lassen sich kleinere Sprachmodelle auch auf dem eigenen Rechner betreiben. Dieser Ratgeber erklärt, wie das funktioniert, welche Hardware nötig ist, welche Programme den Einstieg erleichtern und wofür sich lokale Modelle eignen. Er gibt allgemeine Informationen mit Stand Oktober 2026 und ersetzt keine Rechts- oder IT-Sicherheitsberatung.

INHALT

01	Was ein lokales Sprachmodell ist	3
02	Welche Hardware du brauchst	4
03	Programme für den Einstieg	5
04	Welches Modell zu dir passt	6
05	Wofür lokale KI gut ist und wofür nicht	7
06	Datenschutz realistisch einschätzen und häufige Fragen	8
07	Checkliste zum Abhaken	9
08	Fazit und nächste Schritte	10

DAS WICHTIGSTE IN KÜRZE

Das kannst du sofort umsetzen

- 1 Prüfe den Arbeitsspeicher deines Rechners, bevor du ein Modell auswählst.
- 2 Starte mit einem kleinen Modell und einem Programm mit grafischer Oberfläche.
- 3 Lies die Lizenz des Modells, bevor du es beruflich nutzt.
- 4 Prüfe Fakten aus lokalen Modellen genauso gegen wie bei Cloud-Diensten.



01

KAPITEL

Was ein lokales Sprachmodell ist

Ein Sprachmodell besteht im Kern aus einer großen Datei mit gelernten Zahlenwerten, den sogenannten Gewichten. Bei Cloud-Diensten liegt diese Datei auf den Servern des Anbieters. Bei einem lokalen Modell lädst du sie einmal herunter, und ein Programm auf deinem Rechner berechnet daraus die Antworten.

Viele Hersteller veröffentlichen inzwischen Modelle mit offenen Gewichten. Diese lassen sich herunterladen und ohne Internetverbindung nutzen. Die bekanntesten großen Chat-Dienste gehören nicht dazu; ihre Modelle laufen weiterhin nur beim Anbieter.

Der wichtigste Unterschied für den Alltag: Deine Eingaben werden nicht an einen fremden Server geschickt. Das ist interessant für Entwürfe, interne Notizen oder Texte, die du ungern hochladen möchtest. Gleichzeitig trägst du selbst die Verantwortung für Installation, Updates und Lizenzen.

**MERKE**

Lokal heißt: Das Modell liegt als Datei auf deinem Rechner und arbeitet dort. Die Eingaben verlassen das Gerät dafür nicht.



02 KAPITEL Welche Hardware du brauchst

Wie groß ein Modell ist, wird in Parametern angegeben, etwa 3, 8 oder 70 Milliarden. Je mehr Parameter, desto mehr Speicher braucht das Modell und desto langsamer läuft es auf schwächerer Hardware. Für den Einstieg reichen Modelle im Bereich von etwa 3 bis 8 Milliarden Parametern.

Damit Modelle auf normalen Rechnern laufen, werden sie meist komprimiert angeboten. Diese sogenannte Quantisierung speichert die Gewichte mit weniger Genauigkeit und verkleinert die Datei deutlich. Ein Modell mit rund 8 Milliarden Parametern braucht in einer verbreiteten 4-Bit-Fassung grob 5 Gigabyte Speicher.

Als grobe Orientierung gilt: Mit 16 GB Arbeitsspeicher laufen kleine Modelle auf vielen aktuellen Laptops ordentlich. Eine Grafikkarte mit eigenem Speicher oder ein Rechner mit gemeinsamem Speicher für Prozessor und Grafik beschleunigt die Antworten spürbar. Ohne beides funktioniert es, nur langsamer.

- Arbeitsspeicher in den Systeminformationen nachsehen
- Für den Anfang ein Modell mit 3 bis 8 Milliarden Parametern wählen
- Eine quantisierte Fassung (zum Beispiel 4 Bit) bevorzugen
- Mehrere Gigabyte freien Festplattenspeicher einplanen

**TIPP**

Beginne mit dem kleinsten Modell, das deine Aufgabe ordentlich erledigt. Größer ist nur dann besser, wenn der Rechner es auch flüssig schafft.



03 KAPITEL Programme für den Einstieg

Für den Start musst du nicht programmieren. Programme wie LM Studio bieten eine grafische Oberfläche: Modell suchen, herunterladen, Chatfenster öffnen. Ollama arbeitet über die Kommandozeile und eine Schnittstelle, die andere Programme nutzen können; dazu gibt es grafische Zusatzoberflächen. GPT4All ist eine weitere Möglichkeit mit Chatfenster.

Alle drei waren zum Stand Oktober 2026 kostenlos erhältlich. Lizenzbedingungen und Funktionsumfang ändern sich jedoch, deshalb lohnt vor der Installation ein Blick auf die Website des Herstellers. Lade Programme und Modelle nur aus den offiziellen Quellen herunter.

Der Ablauf ist bei allen ähnlich: Programm installieren, ein Modell aus der eingebauten Liste wählen, den Download abwarten und die erste Frage stellen. Der erste Download dauert je nach Modellgröße und Internetverbindung einige Minuten, danach läuft alles lokal.

! MERKE

Angaben zu Programmen und Preisen sind ein Stand vom Oktober 2026 und ohne Gewähr. Vor der Installation die aktuellen Bedingungen beim Hersteller prüfen.

» BEISPIEL

Du installierst ein Programm mit grafischer Oberfläche, wählst ein Modell mit rund 8 Milliarden Parametern in 4-Bit-Fassung, wartest den Download von etwa 5 Gigabyte ab und bittest das Modell, eine interne Notiz in drei Stichpunkten zusammenzufassen.



04 KAPITEL Welches Modell zu dir passt

Modelle unterscheiden sich in Größe, Sprachqualität und Lizenz. Nicht jedes Modell schreibt gleich gutes Deutsch; einige sind vor allem auf Englisch trainiert. Teste deshalb zwei oder drei Modelle mit deinen eigenen typischen Aufgaben, statt dich auf Ranglisten zu verlassen.

Die Lizenz entscheidet, wofür du ein Modell nutzen darfst. Manche Lizenzen erlauben die freie Nutzung auch im Beruf, andere schränken bestimmte Verwendungen ein. Die Lizenz steht meist auf der Modellseite oder in einer beigefügten Datei. Für die berufliche Nutzung im Zweifel rechtlich prüfen lassen.

Spezialisierte Modelle gibt es zum Beispiel für Programmcode oder für das Beschreiben von Bildern. Für allgemeine Texte reicht ein gutes Allzweckmodell. Wichtiger als das perfekte Modell ist, dass es auf deinem Rechner in vertretbarer Zeit antwortet.

- Zwei bis drei Modelle mit denselben eigenen Aufgaben testen
- Auf die Qualität der deutschen Antworten achten
- Lizenz vor der beruflichen Nutzung lesen
- Antwortzeit auf dem eigenen Rechner beobachten



05 KAPITEL Wofür lokale KI gut ist und wofür nicht

Lokale Modelle eignen sich gut für Aufgaben, bei denen es auf Sprache ankommt: Texte umformulieren, Notizen zusammenfassen, E-Mail-Entwürfe glätten oder Gedanken ordnen. Bei vertraulichen Inhalten ist es ein Vorteil, dass nichts hochgeladen wird.

Schwächer sind sie bei Wissensfragen. Kleine Modelle haben weniger Wissen gespeichert, ihr Wissensstand endet mit dem Training, und sie haben in der Grundeinstellung keinen Zugang zum Internet. Sie können, wie große Modelle auch, überzeugend klingende Fehler produzieren.

Auch beim Tempo und bei langen Texten zeigen sich Grenzen. Lange Dokumente passen nicht immer vollständig in das Kontextfenster eines kleinen Modells. Für komplexe Recherchen bleiben große Cloud-Dienste oder klassische Quellen die bessere Wahl.

» BEISPIEL

Gut geeignet: eine vertrauliche Besprechungsnotiz in fünf Stichpunkte fassen.
Weniger geeignet: aktuelle Preise, Gesetzesstände oder Nachrichten erfragen.

+ TIPP

Nutze lokale Modelle für Sprache und Struktur, nicht als Nachschlagewerk. Fakten prüfst du immer an einer verlässlichen Quelle.



KAPITEL

06 Datenschutz realistisch einschätzen und häufige Fragen

Dass ein Modell lokal läuft, heißt nicht automatisch, dass das Programm drumherum keine Daten sendet. Manche Programme suchen nach Updates oder bieten optionale Nutzungsstatistiken an. Ein Blick in die Einstellungen und die Datenschutzhinweise des Herstellers zeigt, was eingeschaltet ist.

Auch für die Sicherheit deines Rechners bleibst du selbst verantwortlich. Lade Modelle und Programme nur aus offiziellen Quellen und halte sie aktuell. Dieser Ratgeber ersetzt keine IT-Sicherheitsberatung; im beruflichen Umfeld gelten zusätzlich die Regeln deines Arbeitgebers.

HÄUFIGE FRAGEN

? **Brauche ich eine Grafikkarte?**

Nein, kleine Modelle laufen auch ohne. Eine Grafikkarte mit eigenem Speicher oder ein Rechner mit gemeinsamem Speicher beschleunigt die Antworten jedoch deutlich.

? **Kostet das etwas?**

Die genannten Programme und viele Modelle waren zum Stand Oktober 2026 kostenlos erhältlich. Es fallen Strom und Speicherplatz an; Bedingungen können sich ändern.

? **Funktioniert das komplett offline?**

Nach dem Download des Programms und des Modells ja. Für Updates und neue Modelle brauchst du wieder eine Verbindung.

? **Ist ein lokales Modell so gut wie ein großer Cloud-Dienst?**

Meist nicht. Kleine lokale Modelle sind bei Wissen und komplexen Aufgaben schwächer, für viele Schreib- und Zusammenfassungsaufgaben aber ausreichend.



07 ZUM AUSDRUCKEN **Checkliste zum Abhaken**

Geh die Punkte der Reihe nach durch und hake ab, was schon erledigt ist. Offene Punkte sind dein Plan für die nächsten Tage.

- ☐ Ich kenne den Arbeitsspeicher meines Rechners.
- ☐ Ich habe ein Programm aus der offiziellen Quelle installiert.
- ☐ Ich habe mit einem kleinen, quantisierten Modell begonnen.
- ☐ Ich habe die Lizenz des Modells gelesen.
- ☐ Ich habe in den Einstellungen geprüft, ob das Programm Daten sendet.
- ☐ Ich nutze das Modell für Sprache und Struktur, nicht als Faktenquelle.
- ☐ Ich halte Programm und Modell aktuell.



08 ZUM SCHLUSS Fazit und nächste Schritte

FAZIT

Ein lokales Sprachmodell läuft auf dem eigenen Rechner, ohne dass Eingaben einen fremden Server erreichen. Für den Einstieg reichen ein Laptop mit ausreichend Arbeitsspeicher, ein Programm mit grafischer Oberfläche und ein kleines, quantisiertes Modell. Stark sind lokale Modelle bei Sprache und Struktur, schwächer bei Wissen und Aktualität. Wer Lizenzen, Einstellungen und Updates im Blick behält, hat damit ein nützliches Werkzeug für vertrauliche Entwürfe.

DEINE NÄCHSTEN SCHRITTE

- 1 Sieh nach, wie viel Arbeitsspeicher dein Rechner hat.
- 2 Installiere ein Programm mit grafischer Oberfläche und lade ein kleines Modell.
- 3 Teste es mit einer echten Aufgabe aus deinem Alltag und vergleiche das Ergebnis.

WICHTIGER HINWEIS

Inhalte KI-generiert, ohne Gewähr. Keine Rechts- oder IT-Sicherheitsberatung.

Dieser Ratgeber dient ausschließlich der allgemeinen Information und Bildung. Er wurde mit Hilfe künstlicher Intelligenz erstellt und vor der Veröffentlichung automatisiert auf inhaltliche Regeln geprüft; eine redaktionelle Einzelprüfung findet nicht statt. Er kann Fehler enthalten oder veraltet sein und ersetzt keine individuelle Beratung durch eine qualifizierte Fachperson. Die Haftung für Entscheidungen, die du auf Grundlage dieser Inhalte triffst, ist ausgeschlossen, soweit gesetzlich zulässig.

Stand: 7. Oktober 2026 · © 2026 Paolo Schönherr. Private Weitergabe unverändert und kostenlos erlaubt. Impressum, Datenschutz und Nutzungshinweise: www.tipps-ratgeber.de/impressum.html



@ki_tech_tipps

Jeden Tag neue Tipps auf Instagram – alle Ratgeber gratis unter www.tipps-ratgeber.de

Neue Ratgeber jede Woche per E-Mail: kostenlos anmelden unter www.tipps-ratgeber.de, jederzeit abbestellbar.